

New Idea for Multi-hop QA Task

MBIT 凌子扬
2025.9.22

New Idea

1. Multi-hop QA Task 介绍
2. Multi-hop QA Task 问题分析及现有解决方案
3. Theta-gamma Coupling System
4. 切入点, 核心问题
5. Implement
6. Milestone

Multi-hop QA Tasks

- Multi-hop QA任务：
模型需要通过多个推理步骤，整合来自多个信息源的信息才能回答问题的问答任务。
- 多跳问答类型：

Types	Description	Examples
组合型 (Compositional)	解答这类问题需要串联中间实体来完成推理。	Versus创始人为何去世？
比较型 (Comparison)	涉及对不同实体的属性进行比较。	Theodor Haecker 和 Harry Vaughan Watkins 谁活得更久？
相交型 (Intersection)	模型必须找到集合 A 和集合 B 的交集或者差集。	请找出一位既出演过《Unknown》，又出演过《Harry Porter》的演员。
推理型 (Inference)	要求模型依据表述的桥梁事实进行隐含推理。	谁是 Dambar Shah 的孙子
桥接比较型 (Bridge Comparison)	先进行推理，再对推理结果进行比较。	Intercept 和 The Big Money 的导演是否来自同一个国家

Multi-hop QA Tasks

- 代表性Multi-hop QA数据集：

Dataset	Detail	Types	Metrics SOTA	
			EM	F1
HotpotQA	用得最多	Compositional \ Comparison	56.3	69.8
2Wiki	题类别最多	Compositional \ Comparision \ Inference \ Bridge-Comparison	72.5	77.3
Musique	最难	Compositional \ Inference	30.9	42.4

Context Engineering 与 RAG的关系

"RAG is Dead, Context Engineering is King" — with Jeff Huber of Chroma

What actually matters in vector databases in 2025, why "modern search for AI" is different, and how to ship systems that don't rot as context grows.

Aug 20, 2025, Jeff Huber

Jeff提出，我们真正需要关注的是Context Engineering——"决定在任何LLM生成步骤中，什么内容应该出现在上下文窗口中"。

这个定义直击要害：

- 不是所有检索到的内容都应该被使用（Context Rot问题）
- 不是检索越多越好（模型注意力会下降）
- 不是一次检索就够了（可能需要持续动态检索）

Context Engineering包含内循环和外循环^Q：

- 内循环：这一次生成，我该放什么进上下文？
- 外循环：如何基于反馈持续优化上下文选择策略？

- 更需要重视的是检索到的东西在上下文中的排布，让模型可以理解而不是反复复杂思考。
- 上下文的选择和排布是可以动态调整的，可以优化的，而不是一成不变的。

Context Rot: How Increasing Input Tokens Impacts LLM Performance

随着上下文长度增加，模型性能会显著下降。
更长的上下文窗口并不意味着更好的性能。

Generative Benchmarking

RAG：重视检索，上下文够大，忽略放入。
Context Engineering：重视rerank，重视逻辑。

RAG \ Context Engineering \ Multi-hop

RAG

检索
排序
生成

哪些信息该写入 (Write)
哪些信息需要选择 (Select)
哪些必须压缩 (Compress)
哪些应该隔离 (Isolate)

Context Engineering

- 我的上下文窗口里是否包含了真正相关的信息?
- 上下文的顺序和组织是否合理?
- 模型在当前上下文长度下的注意力是否已经衰减?
- 是否需要在生成过程中动态调整上下文?

Multi-hop

需要更加复杂的, 精细的Context Engineering。

Multi-hop QA 深度分析

Common Errors	Description	Reason
Overhopping (过度跳数)	早期无关：推理前期或过程中插入无关步骤	推理问题
	后期无关：完成必要推理后额外阐述冗余信息	
Underhopping (跳数不足)	推理链不完整	推理问题
推理偏差	推理中出现错误：涉及错误文档、实体或关系	检索问题
过度思考	引入非必要信息	推理问题
	重复、循环推理	
问题误解	推理初期误解问题意图	推理问题
覆盖度不足	未能检索到关键证据	检索问题

Multi-hop 中不同类型QA的错误分析

Type	Performance	Details
Comparison	易引发冗余推理	HotpotQA 与 2Wiki 中的比较题，完全正确率 50%-68%，25%-45% 错误源于早期 / 后续无关，对称表述促使模型过度探索。
Inference	错误率最高且易过度思考	MuSiQue 与 2Wiki 中的推理题需隐性推理与多步逻辑，无强词汇提示，错误类型多样（早期 / 后续无关、误解、跳数不足）
Compositional	组合题暴露整合缺陷	此类题目考验模型整合离散事实的能力，小型模型常出现部分正确链
Bridge	桥接比较题易解决	

现有方案 Chain of RAG

Thomas Parker Sanborn was a model for the protagonist in the only novel by a poet originally from what country?

托马斯·帕克·桑伯恩是某位诗人唯一一部小说中主人公的原型，这位诗人最初来自哪个国家？

托马斯·帕克·桑伯恩是哪一部小说的主人公原型？

这部小说的作者是否只写了唯一一部小说？

这部小说的作者来源哪个国家？

Query: Thomas Parker Sanborn was a model for the protagonist in the only novel by a poet originally from what country?

RAG without Chain-of-Retrieval

Final Answer: **Italian** ✗

CoRAG (Ours)

Sub-query 1: What country is the poet originally from?

直接问诗人国籍 ✗

Sub-answer 1: Hungary, Romania, Switzerland, China, Ukraine, France, Turkey.

Sub-query 2: What is the name of the poet who wrote the only novel?

问谁只写了一部小说 ✗

Sub-answer 2: Emily Brontë

Sub-query 3: What country is the poet who wrote the only novel originally from?

Sub-answer 3: United States

Sub-query 4: What is the name of the poet who wrote the only novel that Thomas Parker Sanborn was a model for?

Sub-answer 4: George Santayana

Sub-query 5: What poet wrote the only novel that Thomas Parker Sanborn was a model for?

Sub-answer 5: George Santayana

Sub-query 6: What country is the poet George Santayana originally from?

Sub-answer 6: Spain.

Final Answer: **Spain** ✓

现有方案 Chain of RAG 缺陷

Deficiency	Description	Metaphor
推理脆弱性 Error-Compounding	取决于前一步的问题和答案，早期危害大。	第一个子问题找错了，比如人民地名找错，后面的所有检索和推理都毫无意义。
无法重构逻辑空间 无错误修复能力	中间出现错误只会多余思考，无法重新检索，只能原地思考。	只会检索一次，如果发现检索的东西没有自己想要的，只能原地愣住，或者幻觉分析，会经常输出“maybe”。
注意力衰减	回答最终问题时注意力偏移，仅关注在最后一个子问题上。	找着找着，分析分析，就会忘记自己原来的根本问题到底是什么了。
检索技术、检索成本	检索工具没有更新，检索次数按照问题复杂度和子问题需要线形增加。	

Theta-Gamma Coupling Mechanism

人脑的Theta-Gamma机制是一种神经振荡的跨频耦合现象，其中慢速的theta波（4-8 Hz）调控局部快速的gamma波（30-150 Hz）的幅值和相位。

该机制被认为是大脑**整合分布式信息**的核心“时钟”框架：theta振荡提供一个周期性时间窗口，而gamma振荡在此窗口内以“子周期”形式编码不同神经元集群的放电，实现多项目或特征的序列化绑定，即gamma周期嵌套于theta周期，构成可动态重构的信息单元。

John, 2013 Mar 20, The Theta-Gamma Neural Code

Empirical Proofs


- 当解决复杂问题时：
 - 人脑 theta-gamma 耦合强度与任务目标相关度呈正相关 $r=0.78$
 - AI的注意力与目标相关度仅 $r=0.32$ (Wang et al., PNAS 2023)。
- 面对**角色别名**问题时，人脑 gamma 振荡同步性提高 40%，表明**更强的概念绑定** (Lakatos et al., Neuron 2023)。
- **动态重构**：当问题有**隐性简化可能**时，人脑前额叶 theta 功率下降 35%，表明认知负荷降低 (Hsieh et al., Nature Neuroscience 2022)。
- **错误检测**：**前扣带回 (ACC)** 在错误发生前 300ms 就产生“错误相关 negativity”信号 (Alexander & Brown, Nature Reviews Neuroscience 2022)。
- 人脑在解决多跳问题时，海马-皮层 theta 同步性提高 50%，表明**长期记忆与工作记忆的整合** (Schomburg et al., Science 2020)。

Theta-Gamma Coupling Mechanism - Inspired

人脑并非像计算机那样串行解决多跳问题。

同时，人脑不是“按部就班”推理，而是通过 theta-gamma 机制动态重构问题空间。

在多跳任务中，海马体按 theta 节奏依次提取记忆片段，前额叶则在每个 gamma 窗口内对当前信息进行加工和保持，从而实现跨跳信息整合。



前面Jeff也提到了
“内循环” + “外循环”

切入点，核心问题

推理路径
单一性

不可重构，
路径错了就
全错。

注意力衰减

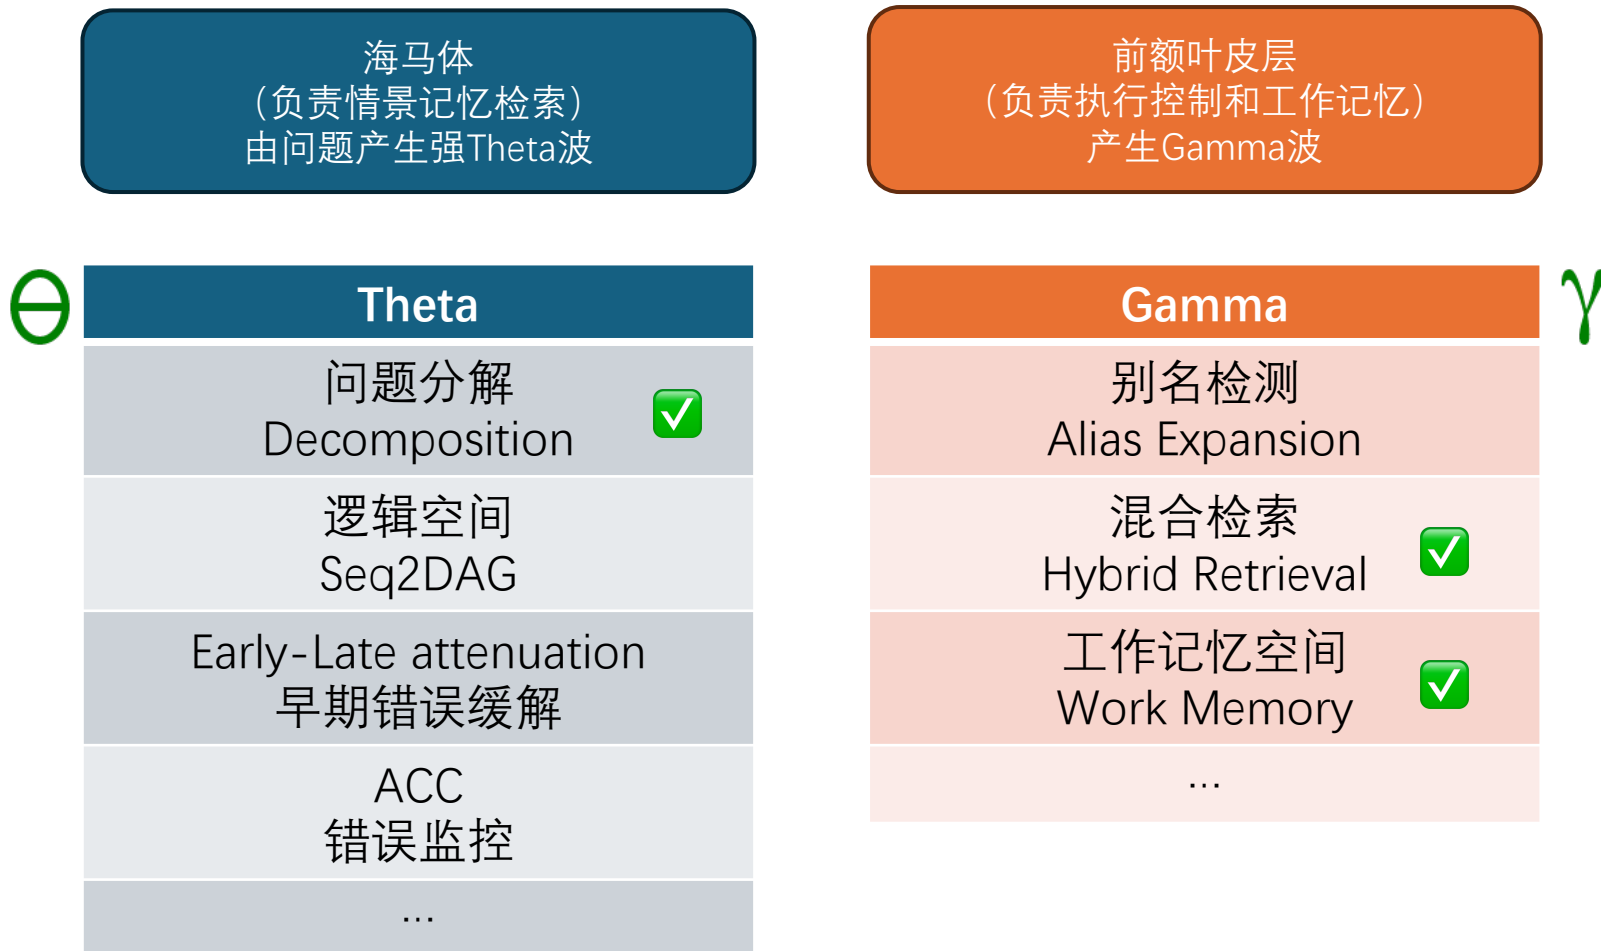
回答最后一
跳问题注意
力衰减。

推理脆弱性

早期错误会
导致雪崩错
误。

- 可动态重构逻辑空间
 - 初始生成多条路径DAG图（有向无环图），并根据检索内容动态更新推理路径。
- 注意力保持
 - 始终在theta节律-逻辑空间解决问题，gamma检索的子问题，子实体保持在工作记忆空间，不影响推理链注意力保持。
- 缓解推理脆弱性
 - Early-Late Attenuation, 早期错误权重加大。
 - ACC 错误感知与修复：目标是防止早期错误放大并节省不必要计算。

Theta-Gamma Coupling Mechanism - Inspired




Early-Late Attenuation: 用于训练中早期错误, 正、负样本的权重增加。
ACC: 一个实时监控器, 基于证据置信、不一致性与检索/推理的边际效用来决定是否继续、回滚、扩展或询问澄清, 目标是防止早期错误放大并节省不必要计算。

Upcoming Alternative Conferences

Conference	CCF	Overlap Scope	Deadline	Category
EDBT	B	knowledge management; Query processing and optimization techniques	2025.10.8	DM
SIGMOD	A	Query processing and optimization; Natural language queries	2025.10.18	DM
ICDE	A	Query Processing and Optimization	2025.10.28	DM
DASFAA	B	Neural networks and deep learning; Information retrieval and summarization	2025.10.28	DM
SIGIR	A		2026.1	DM
KDD	A		2026.2	DM
ACL	A		2025.2	NLP

Workflow

Query When did the people who captured Malakoff come to the region where Philipsburg is located?



θ Agent Tom captured Malakoff, Philipsburg is located in America. When did Tom come to America?

γ Agent

Theta-Gamma



注意力衰减 \ 推理脆弱性



γ Worker



θ Scheduler

推理轨迹图 + 动态缺口预测期 + ACC + early-late attenuator



双端检索 + 一致性耦合

seq2DAG

Thomas Parker Sanborn was a model for the protagonist in the only novel by a poet originally from what country?

Layer 0: [Thomas Parker Sanborn]



Layer 1: [slot_novel ← 小说, 其主角原型是 Thomas Parker Sanborn?]



Layer 2: [slot_poet ← slot_novel 的作者是谁?]



Layer 3: [is_valid? ← slot_poet 是诗人且只写一本小说?] → (可选验证层)



Layer 4: [slot_country ← slot_poet 的原籍国家是?] ← FINAL ANSWER

Query: Thomas Parker Sanborn was a model for the protagonist in the only novel by a poet originally from what country?

RAG without Chain-of-Retrieval

Final Answer: **Italian** ✗

CoRAG (Ours)

Sub-query 1: What country is the poet originally from?

Sub-answer 1: Hungary, Romania, Switzerland, China, Ukraine, France, Turkey.

Sub-query 2: What is the name of the poet who wrote the only novel?

Sub-answer 2: Emily Brontë

Sub-query 3: What country is the poet who wrote the only novel originally from?

Sub-answer 3: United States

Sub-query 4: What is the name of the poet who wrote the only novel that Thomas Parker Sanborn was a model for?

Sub-answer 4: George Santayana

Sub-query 5: What poet wrote the only novel that Thomas Parker Sanborn was a model for?

Sub-answer 5: George Santayana

Sub-query 6: What country is the poet George Santayana originally from?

Sub-answer 6: Spain.

Final Answer: **Spain** ✓

子问题检索问题

- **别名 mismatch**: entity 在维基中常用其他写法（缩写、别名、同义词）。
- **slot query 不稳**: 同一个 relation 在语料中有多种表述（“nationality” vs “is an American director”）。
- **retriever 偏短语匹配**: 容易漏掉 paraphrase / 描述性句子。


Human Brain Multi-hop Mechanism

- **工作记忆 (Working Memory) — 前额叶皮层 (PFC) 与顶叶协同**
保存中间结果、维护子目标、控制信息流。PFC 提供任务规则、顺序控制和抑制干扰（比如抑制无关记忆）。
- **情节/关系记忆 (Relational & Episodic Memory) — 海马与内侧颞叶 (Hippocampus / MTL)**
强于把零散事实以“关系”形式联系起来（A 与 B 的关系），在把不同片段串成链时非常关键。海马也支持对记忆片段进行快速绑定与检索。
- **语义记忆 (概念知识) — 颞叶中部/下颞叶 (Temporal cortex)**
储存事实性知识与概念表征，是检索“事实”而非具体事件的来源。
- **执行控制与策略选择 — 前额叶/基底神经节 (PFC + Basal Ganglia)**
基底神经节提供“门控”机制，决定什么时候把检索内容允许进入工作记忆或被替换
- **注意与空间/关系整合 — 顶叶 (Parietal cortex)**
支持关注相关片段并完成序列/空间上关系的整合。
- **默认模式网络 (DMN: 包括内侧PFC、海马回、后扣带等)**
与内部思考、情景想象和自发回放相关；在“心智模拟”和把不同记忆片段组合成连贯故事时常被激活。

Chain-of-RAG

- **机制**：把原始 query 分解成子问题，**每一步子问题 → 检索 → 回答**，然后把回答拼接进入下一个子问题。
- **特点**：
- 逐步 “retrieve-answer-pass along”。
- 每一步都是 局部独立调用，上下文依赖前一步结果。
- **典型弱点**：
 - 如果前一步 answer 错了，后续链条都会错（error propagation）（经典的推理脆弱性）。
 - 缺少并行或全局评估机制。
 - decomposition 与检索器不耦合检索感知的分解
- 主要流程偏“串行”，并不善于并行探索多条候选链
- **错误传播（error compounding）仍是主问题**

RAG workflow



- 1、分块大小
- 2、分块策略

- 1、检索不到黄金块
- 2、倾向短或包含字面匹配的片段，漏掉更长的语义匹配。
- 3、预训练 embedding 在目标域上效果差
- 4、没有充足的标注问—答对训练检索器，导致召回差。

- 1、区分不了黄金与噪声
- 2、cross-encoder 的计算成本比较大
- 3、证据跨chunk时，单独精排不足以衡量组合价值

- 1、在高风险场景下需要验证来控制hallucination
- 2、实时性
- 3、矛盾对

- 1、多条证据权重类似时，平均选择来源
- 2、有限上下文中放入最有代表性的证据
- 3、幻觉自动补全

Gating

- **可学习的检索门控**：借鉴基底神经节-PFC 的 gating 思想，让模型学会何时把检索结果写入工作记忆（context buffer）。
- **序列回放机制**：引入“回放/重写”步骤，让模型在内部短时间模拟多条候选路径并打分（类似A*搜索加模型评分）。
- 设置一个工作记忆agent？
长期记忆的逻辑框架怎么微调？ Decomposition？
- 工作记忆怎么设置呢？